LMU
LUDWIG-MAXIMILIANS-UNIVERSITÄT MÜNCHEN
INSTITUT FÜR INFORMATIK
LEHRSTUHL FÜR MOBILE UND VERTEILTE SYSTEME

Trends in Mobilen und Verteilten Systemen

Kontinuierliches Lernen mit fixierten Netzwerken: Eine Analyse von SupSup

Bearbeiter: Yusuf Malik Durmus

Betreuer: Julian Schönberger

Aufgabensteller: Prof. Dr. Claudia Linnhoff-Popien

Dokument erstellt
14. Januar 2026

Kontinuierliches Lernen mit fixierten Netzwerken: Eine Analyse von SupSup

Zusammenfassung

Das sequenzielle Lernen mehrerer Aufgaben stellt für tiefe neuronale Netze eine fundamentale Herausforderung dar, da die Anpassung von Gewichten an neue Datenverteilungen häufig zu einem drastischen Leistungsabfall bei zuvor erlernten Aufgaben führt. Dieses Phänomen, bekannt als katastrophales Vergessen, ist insbesondere dann kritisch, wenn ein Zugriff auf frühere Trainingsdaten nicht mehr möglich ist und das Training separater Modelle für jede Aufgabe aufgrund des enormen Ressourcenbedarfs moderner Architekturen ineffizient wäre. Diese Arbeit untersucht den Ansatz „Supermasks in Superposition“ (SupSup), welcher eine neuartige Technik zur Bewältigung dieses Problems vorschlägt. Anstatt Parameter zu trainieren, nutzt SupSup ein festes, zufällig initialisiertes Basisnetzwerk und erlernt für jede Aufgabe eine spezifische binäre Maske. Da die Gewichte unverändert bleiben, ist ein Vergessen per Definition ausgeschlossen. Ein zentraler Beitrag ist die Fähigkeit, die korrekte Maske zur Inferenzzeit auch ohne bekannte Aufgabenidentität zu bestimmen. Dies erfolgt durch einen gradientenbasierten Optimierungsschritt (One-Shot), der eine Überlagerung von Masken findet, welche die Entropie minimiert. Die Evaluation zeigt, dass dieser Ansatz auf tausende Aufgabenvariationen skaliert und etablierte Methoden in komplexen Szenarien deutlich übertrifft.

Inhaltsverzeichnis

1 Einleitung **1**

2 Grundlagen **1**
2.1 Kontinuierliches Lernen und Katastrophales Vergessen 1
2.2 Subnetzwerke in zufälligen Netzen 1

3 Verwandte Arbeiten **2**

4 Ansatz **2**
4.1 Szenarien und Taxonomie 3
4.2 Training der Supermasks 3
4.3 Inferenz durch Superposition 3
4.4 Erweiterungen 4

5 Versuchsaufbau **4**
5.1 Datensätze, Architekturen und Vergleichsmethoden 4
5.2 Training und Hyperparameter 4

6 Ergebnisse **5**
6.1 Leistung bei bekannter Aufgabenidentität (GG) 5
6.2 Inferenz und Skalierbarkeit (GN) 5

7 Fazit **7**

Literatur **8**

1 Einleitung

Während biologische Systeme in der Lage sind, kontinuierlich neues Wissen zu akkumulieren, ohne bestehende Fähigkeiten zu verlieren, stehen künstliche neuronale Netze vor dem *Stabilitäts-Plastizitäts-Dilemma* [12]. Das sequenzielle Training auf neuen Datenverteilungen führt in herkömmlichen Modellen zur Zerstörung vorheriger Repräsentationen, ein Phänomen, bekannt als katastrophales Vergessen (sog. eng. Catastrophic Forgetting) [3]. Da die Ursache dieses Problems primär in der destruktiven Modifikation der Gewichte liegt, untersucht diese Arbeit das Modell „Supermasks in Superposition“ (SupSup) [18]. Dieser Ansatz umgeht das Dilemma fundamental, indem er auf einem festen, zufällig initialisierten Basisnetzwerk operiert.

SupSup basiert auf zwei zentralen Prinzipien: der Existenz leistungsfähiger Teilnetze in zufälligen Gewichten [13] sowie der Inferenz der unbekannten Aufgaben-Identität durch ein gradientenbasiertes Optimierungsproblem. Für jede Aufgabe wird lediglich eine binäre Maske (sog. eng. Supermask) gelernt, wobei eine Erweiterung mittels Hopfield-Netzwerken die effiziente Speicherung tausender Masken als Attraktoren ermöglicht. Nach der Einführung der Grundlagen in Abschnitt 2, wird in Abschnitt 4 die Methodik detailliert beschrieben und in Abschnitt 6 evaluiert.

2 Grundlagen

Das Verständnis von SupSup setzt zwei Kernkonzepte voraus: Die Formalisierung des Vergessens in sequenziellen Lernumgebungen sowie die Existenz leistungsfähiger Subnetzwerke in zufälligen Initialisierungen.

2.1 Kontinuierliches Lernen und Katastrophales Vergessen

Beim kontinuierlichen Lernen wird ein Modell f, parametrisiert durch Gewichte W, sequenziell auf einer Reihe von k Aufgaben trainiert. Für jede Aufgabe $t \in \{1, \ldots, k\}$ existiert ein Datensatz $\mathcal{D}_t$ mit Eingaben x und Zielen y. Ein ideales Modell minimiert den Verlust über alle bisher gesehenen Aufgaben. Werden die Gewichte W jedoch mittels Gradientenabstieg (sog. eng. Gradient Descent) ausschließlich auf der aktuellen Aufgabe t optimiert, verschiebt sich die Parameterkonfiguration oft in einen Bereich, der für vorherige Aufgaben $t-1$ suboptimal ist. Dies führt häufig zu einem Leistungsabfall auf früheren Datenverteilungen und wird als katastrophales Vergessen bezeichnet [3, 10, 11]. In traditionellen Ansätzen wird versucht, dies durch Regularisierungsterme oder das erneute Einspielen alter Daten (Replay) zu mitigieren. [16]

2.2 Subnetzwerke in zufälligen Netzen

Die Basis von SupSup bildet die Erkenntnis, dass moderne neuronale Netze stark überparametrisiert sind. Ramanujan et al. [13] zeigten, dass in einem ausreichend großen, zufällig initialisierten Netzwerk $f(x, W)$ mit fixierten Gewichten W Teilnetze existieren, die mit dem originalen Netzwerk konkurrieren können. Ein solches Teilnetz wird durch eine binäre Maske $M \in \{0,1\}^{|W|}$ definiert, wobei $|W|$ die Anzahl aller trainierbaren Parameter des festen Basisnetzwerks bezeichnet. Die Berechnung der Ausgabe erfolgt durch das elementweise Produkt (Hadamard-Produkt, notiert als $\odot$) zwischen den Gewichten und der Maske:

$$y = f(x, W \odot M) \tag{1}$$

Da W hierbei unverändert bleibt, werden lediglich die Werte der Maske M optimiert, um das passende Subnetzwerk zu finden. Da die ursprünglichen Gewichte nicht überschrieben werden, ist ein Vergessen durch Gewichtsänderung per Definition ausgeschlossen.

3 Verwandte Arbeiten

Wang et al. [16] unterteilen Ansätze systematisch in fünf Hauptkategorien (siehe Abb. 1).

Dominierend sind *Regularisierungsansätze*, die katastrophales Vergessen durch Bestrafung von Gewichtsänderungen verhindern; hierzu zählen EWC [7] und Synaptic Intelligence (SI) [19], welche die Wichtigkeit von Parametern schätzen. *Replay-Methoden* [14] hingegen speichern Teile vergangener Daten oder generieren diese neu. Ergänzend existieren *optimierungsbasierte* (z.B. Gradientenprojektion) und *repräsentationsbasierte* Ansätze [16].

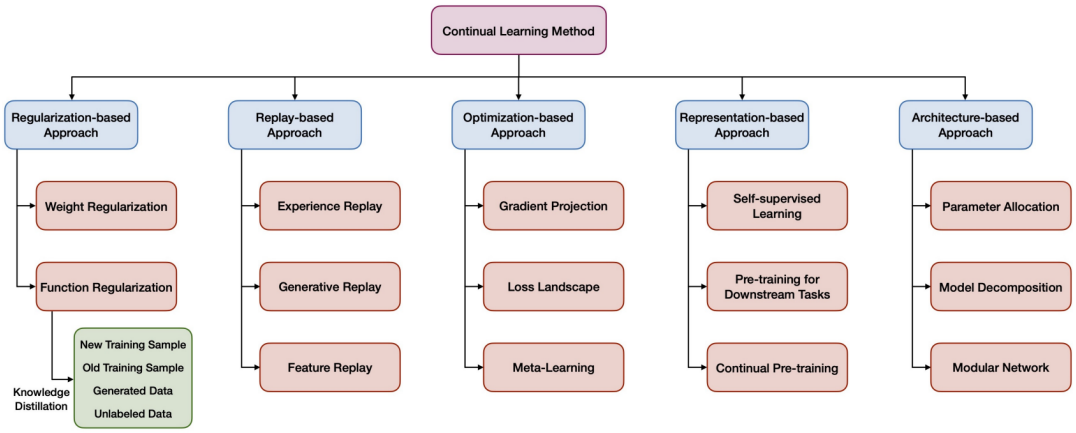

Abbildung 1: Taxonomie von Continual Learning Methoden nach [16]. SupSup fällt in den Bereich der *Architecture-based Approaches*

SupSup lässt sich in die Kategorie der *architekturbasierten Methoden* einordnen, spezifischer in den Bereich der *Parameter Allocation*. Während Ansätze wie Progressive Neural Networks [15] jedoch für neue Aufgaben wachsen, isoliert SupSup Parameter in einem fixierten Netzwerk durch Maskierung [9]. Im Gegensatz zu ähnlichen Methoden (z.B. Piggyback) löst SupSup dabei auch das Problem der Inferenz ohne bekannte Aufgabenidentität.

4 Ansatz

Der Ansatz von SupSup [18] zerlegt das Problem des kontinuierlichen Lernens in zwei Komponenten: Das Erlernen isolierter Subnetzwerke (Supermasks) für jede Aufgabe und die dynamische Identifikation der korrekten Maske zur Inferenzzeit mittels Superposition.

4.1 Szenarien und Taxonomie

Die Methodik klassifiziert Lernszenarien anhand eines zweistelligen Buchstabencodes, der die Verfügbarkeit der Aufgabenidentität (Task ID) beschreibt. Der erste Buchstabe bezieht sich auf die Trainingsphase, der zweite auf die Inferenzphase (**G** = Given/Gegeben, **N** = Not given/Nicht gegeben). Zusätzlich wird unterschieden, ob sich die Aufgaben den Ausgaberaum teilen (**s** = shared) oder disjunkte Klassenräume besitzen (**u** = unshared).

Im Szenario **GG** ist die Task-ID sowohl im Training als auch im Test verfügbar. Dies erlaubt eine deterministische Maskenwahl: Da dem Modell die Identität t bekannt ist, wird die zugehörige Maske M^t direkt abgerufen, ohne dass eine Inferenz oder Suche notwendig ist. Die eigentliche Herausforderung liegt im Szenario **GN** (ID nur im Training bekannt). Hier muss das Modell zur Laufzeit entscheiden, welche Maske für den Input x zuständig ist. Im unshared Fall (GNu) ist dies kritisch, da die Ausgabeneuronen ohne den Kontext der Task-ID keine eindeutige Semantik besitzen. Das Szenario **NN** wird mittels des *Labels Trick* [20] effektiv auf GN reduziert. Dabei wird das Auftreten eines Labels, das in den bisherigen Aufgaben nicht vorhanden war, als Indikator für den Beginn einer neuen Aufgabe gewertet. Somit kann das System implizit Task-Grenzen erkennen und eine neue ID vergeben.

4.2 Training der Supermasks

Das Training erfolgt analog für alle Szenarien. Für jede Aufgabe t wird eine binäre Maske M^t mittels des *Edge-Popup*-Algorithmus [13] gelernt. Dabei werden kontinuierliche Scores optimiert, die entscheiden, welche Gewichte des fixierten W aktiv geschaltet werden. Da die Basisgewichte W global fixiert bleiben, beschränken sich Änderungen ausschließlich auf die aktuelle Maske. Ein Überschreiben der für alte Aufgaben relevanten Parameterkonfigurationen ist somit technisch ausgeschlossen.

4.3 Inferenz durch Superposition

Ist die Task-ID unbekannt (GN), nutzt SupSup eine gewichtete Superposition aller k Masken:

$$y = f\left(x, W \odot \sum\nolimits_{i=1}^{k} \alpha_i M^i\right) \tag{2}$$

Die Koeffizienten α repräsentieren den Glauben, dass Maske i korrekt ist. Das Ziel ist die Minimierung der Ausgabe-Entropie $\mathcal{H}$ bezüglich α. Dabei wird $\mathcal{H}$ als die Shannon-Entropie der vorhergesagten Klassenwahrscheinlichkeiten p definiert ($\mathcal{H}(p) = -\sum_c p_c \log p_c$), wobei niedrige Werte eine hohe Zuversicht des Modells signalisieren.

One-Shot: Dieser Algorithmus nutzt einen einzigen Gradientenschritt, was formal einem Schritt des Frank-Wolfe-Algorithmus entspricht. Die Maske mit dem steilsten Abstieg im Entropie-Gradienten wird gewählt: $j = \arg\max_i(-\nabla_{\alpha_i}\mathcal{H})$. Dies ermöglicht eine Inferenz in $O(1)$.

Binary: Ähnlich der binären Suche eliminiert dieser Algorithmus iterativ Masken. In jedem Schritt wird die Hälfte der Masken mit dem geringsten negativen Gradienten (geringster Entropie-Abfall) verworfen und α renormalisiert. Dies führt in $O(\log k)$ Schritten zur Lösung.

4.4 Erweiterungen

Da die Entropie $\mathcal{H}$ anfällig für Overconfidence ist, führt SupSup *Superfluous Neurons* ein. Diese zusätzlichen Ausgabeneuronen fungieren als Ausreißer-Detektoren; die alternative Zielfunktion $\mathcal{G}$ minimiert deren Aktivierung. Zur Skalierung wird zudem vorgeschlagen, Masken nicht explizit zu speichern, sondern als Attraktoren in einem Hopfield-Netzwerk fester Größe zu kodieren [6].

5 Versuchsaufbau

Die Evaluation prüft Skalierbarkeit und Inferenzfähigkeit in den Szenarien GG und GN.

5.1 Datensätze, Architekturen und Vergleichsmethoden

Für das Szenario **GG** werden die Benchmarks *SplitCIFAR100* (20 Aufgaben) und *SplitImageNet* (100 Aufgaben) verwendet. Als Architektur dient für ImageNet ein Standard ResNet-50 [5] und für CIFAR ein modifiziertes ResNet-18 mit reduzierter Kanalanzahl, analog zu den Experimenten von Wen et al. [17]. Hierbei wird SupSup gegen *BatchEnsemble* (BatchE) [17] und *Parameter Superposition* (PSP) [1] verglichen, um Genauigkeit und Speichereffizienz zu evaluieren.

Im Szenario **GN** kommen Varianten des MNIST-Datensatzes (*Split-, Permuted-, RotatedMNIST*) zum Einsatz. Hier werden kleinere Netzwerke genutzt: Ein Fully-Connected Netzwerk mit zwei Hidden-Layers der Größe 1024 (FC 1024-1024), wie es von Cheung et al. [1] verwendet wurde, sowie die LeNet 300-100 Architektur [8], die auch im Kontext der Lottery Ticket Hypothesis von Frankle und Carbin [2] etabliert ist. Als Vergleichsgrundlage dienen Regularisierungsansätze wie *Synaptic Intelligence* (SI) [19] und *Online EWC* [7], da diese ebenfalls keine Task-ID zur Inferenz benötigen.

5.2 Training und Hyperparameter

Da W fixiert ist, werden nur Masken-Scores trainiert. Die Hyperparameter orientieren sich an den Baselines (siehe Tabelle 1).

Tabelle 1: Hyperparameter-Einstellungen für die verschiedenen Experimente. Die Werte folgen den Standards aus [17] für GG und [1] für GN.

Szenario	**Datensatz**	**Epochen/Steps**	**Optimierer (LR)**	**Batch**
GG	SplitCIFAR100	250 Epochen	Adam (10^{-3})	128
GG	SplitImageNet	100 Epochen	Adam (10^{-3})	256
GN	PermutedMNIST	1000 Batches	RMSProp (10^{-4})	128
GN	RotatedMNIST	1000 Batches	RMSProp (10^{-4})	128

6 Ergebnisse

Die Evaluation demonstriert, dass SupSup in beiden Szenarien (GG und GN) den Stand der Technik übertrifft. Um die Ergebnisse korrekt einzuordnen, werden im Folgenden primär drei Metriken betrachtet: Die Average Top-1 Accuracy misst die mittlere Klassifikationsgüte über alle gelernten Aufgaben. Die Speichereffizienz wird in Megabytes (MB) ausgewiesen, um den Vorteil der binären 1-Bit-Masken gegenüber den 32-Bit-Gleitkommazahlen herkömmlicher Methoden (wie BatchEnsemble) verdeutlichen zu können. Im GN-Szenario dient zudem die Stabilität der Inferenz bei steigender Aufgabenanzahl als Maß für die Skalierbarkeit.

6.1 Leistung bei bekannter Aufgabenidentität (GG)

Im Szenario GG zeigt sich, dass die Beschränkung auf ein fixiertes Basisnetzwerk keinen negativen Einfluss auf die Vorhersagequalität hat. Wie in Abb. 2 (links) dargestellt, nähert sich SupSup auf *SplitImageNet* der oberen Schranke (Upper Bound: separates Modell pro Task) bis auf wenige Prozentpunkte an, benötigt jedoch signifikant weniger Speicherplatz als *BatchEnsemble* (BatchE). Während BatchE für 81,50% Genauigkeit ca. 125 MB benötigt, erreicht SupSup 88,68% Genauigkeit bei nur ca. 101 MB Speicherbedarf [18]. Zudem zeigt Abb. 2 (rechts) auf *SplitCIFAR100*, dass die Initialisierung neuer Masken durch den Mittelwert vergangener Masken ("Transfer") die Konvergenz beschleunigt und die Endgenauigkeit im Vergleich zu zufälliger Initialisierung erhöht.

Algorithm	Avg Top 1 Accuracy (%)	Bytes
Upper Bound	92.55	10222.81M
SupSup (GG)	89.58	195.18M
	88.68	100.98M
	86.37	65.50M
BatchE (GG)	81.50	124.99M
Single Model	-	102.23M

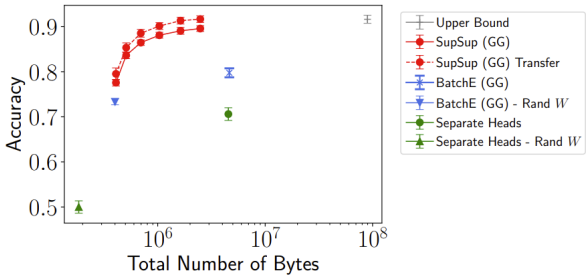

Abbildung 2: Vergleich der Genauigkeit und des Speicherbedarfs auf SplitImageNet (links) und SplitCIFAR100 (rechts). SupSup übertrifft BatchEnsemble (BatchE) bei geringerem Speicherverbrauch [18].

6.2 Inferenz und Skalierbarkeit (GN)

Das zentrale Ergebnis der Arbeit ist die Fähigkeit von SupSup, Aufgaben ohne explizite Task-ID zu lösen. Obwohl Regularisierungsansätze wie *Online EWC* oder *SI* in der Literatur dominieren, da sie keine speicherintensiven Daten-Buffer benötigen und die Modellgröße konstant halten, stoßen sie hier an ihre Grenzen: Sie kollabieren auf *PermutedMNIST* bereits nach ca. 50 Aufgaben (Genauigkeit $< 40\%$). SupSup hingegen skaliert erfolgreich auf 2500 Aufgaben (siehe Abb. 3). Selbst im Szenario **NNs**, in dem dem Modell während des Trainings keine Task-Grenzen mitgeteilt wurden, validiert der *Labels Trick* seine Effektivität durch konstant hohe Genauigkeit.

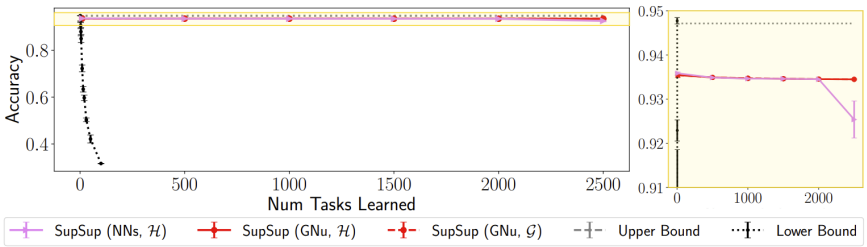

Abbildung 3: Skalierbarkeit auf 2500 Aufgaben (PermutedMNIST). SupSup hält die Genauigkeit stabil und übertrifft Regularisierungsansätze deutlich [18].

Besonders bemerkenswert ist die Überlegenheit gegenüber methodischen Alternativen auf dem schwierigeren *RotatedMNIST*-Datensatz. Wie Abb. 4 zeigt, übertrifft SupSup im GN-Szenario (unbekannte Task-ID) sogar Methoden wie *PSP* und *BatchE*, obwohl diese im einfacheren GG-Szenario (bekannte Task-ID) operieren. Dies unterstreicht die Effektivität der Superposition zur Disambiguierung ähnlicher Aufgaben. Die Robustheit des *One-Shot*-Algorithmus hängt dabei maßgeblich von der Dimension des Ausgaberaums ab. Abb. 5 illustriert, dass eine Erhöhung der *Superfluous Neurons* (z.B. $s = 200$ vs. $s = 25$) die Inferenzgenauigkeit stabilisiert.

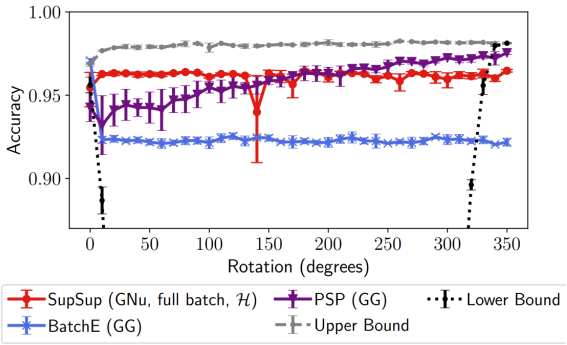

Abbildung 4: Auf RotatedMNIST schlägt SupSup (GN) Baselines, die Task-IDs nutzen (GG). [18].

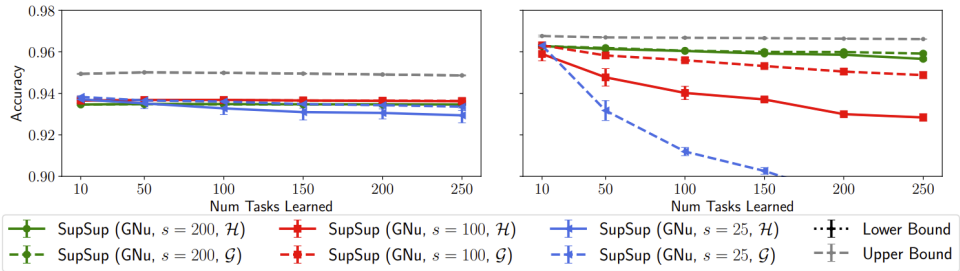

Abbildung 5: Einfluss der Superfluous Neurons (s) auf die Inferenzqualität [18].

7 Fazit

Diese Arbeit untersuchte den Ansatz SupSup, welcher katastrophales Vergessen durch die strikte Trennung von fixierten, zufällig initialisierten Netzwerkgewichten und aufgabenspezifischen Masken eliminiert. Die Analyse zeigte, dass die Formulierung der Aufgaben-Identifikation als Optimierungsproblem (Superposition) es ermöglicht, selbst in Szenarien ohne bekannte Task-ID (GN und NNs) tausende von Aufgabenvariationen sequenziell zu erlernen. Eine fundamentale Voraussetzung hierfür ist jedoch, dass das Basisnetzwerk über hinreichend Kapazität verfügt: Es können nur solche Aufgaben erlernt werden, für die in der zufälligen Initialisierung bereits ein leistungsfähiges Subnetzwerk existiert, wie es Ramanujan et al. als Hidden Lottery Tickets beschreiben [13].

Trotz der hohen Skalierbarkeit auf synthetischen Benchmarks wie PermutedMNIST bleibt die Übertragbarkeit auf komplexere, natürliche Datenverteilungen eine offene Forschungsfrage. Da die Inferenzqualität stark von der Kalibrierung des Modells abhängt (Vermeidung von Overconfidence auf falschen Tasks), liegt das größte Potenzial für zukünftige Arbeiten in der Integration robusterer Trainingsziele. Insbesondere die Kombination mit Self-Supervised Learning [4] oder energiebasierte Modellen könnte die Diskriminierbarkeit der Masken weiter schärfen und die Abhängigkeit von *Superfluous Neurons* verringern.

Literatur

[1] Brian Cheung, Alex Terekhov, Yubei Chen, Pulkit Agrawal, and Bruno Olshausen. Superposition of many models into one, 2019.

[2] Jonathan Frankle and Michael Carbin. The lottery ticket hypothesis: Finding sparse, trainable neural networks, 2018.

[3] Robert M French. Catastrophic forgetting in connectionist networks. *Trends in cognitive sciences*, 3(4):128–135, 1999.

[4] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning, 2020.

[5] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition, 2015.

[6] John J. Hopfield. Neural networks and physical systems with emergent collective computational abilities. *Proceedings of the National Academy of Sciences of the United States of America*, 79 8:2554–8, 1982.

[7] James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A. Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, Demis Hassabis, Claudia Clopath, Dharshan Kumaran, and Raia Hadsell. Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13):3521–3526, March 2017.

[8] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.

[9] Arun Mallya, Dillon Davis, and Svetlana Lazebnik. Piggyback: Adapting a single network to multiple tasks by learning to mask weights, 2018.

[10] James L McClelland, Bruce L McNaughton, and Randall C O'Reilly. Why there are complementary learning systems in the hippocampus and neocortex: insights from the successes and failures of connectionist models of learning and memory. *Psychological review*, 102(3):419, 1995.

[11] Michael McCloskey and Neal J Cohen. Catastrophic interference in connectionist networks: The sequential learning problem. In *Psychology of learning and motivation*, volume 24, pages 109–165. Elsevier, 1989.

[12] German Ignacio Parisi, Ronald Kemker, Jose L. Part, Christopher Kanan, and Stefan Wermter. Continual lifelong learning with neural networks: A review. *Neural networks : the official journal of the International Neural Network Society*, 113:54–71, 2018.

[13] Vivek Ramanujan, Mitchell Wortsman, Aniruddha Kembhavi, Ali Farhadi, and Mohammad Rastegari. What's hidden in a randomly weighted neural network? *CoRR*, abs/1911.13299, 2019.

[14] Sylvestre-Alvise Rebuffi, Alexander Kolesnikov, Georg Sperl, and Christoph H. Lampert. icarl: Incremental classifier and representation learning, 2017.

[15] Andrei A. Rusu, Neil C. Rabinowitz, Guillaume Desjardins, Hubert Soyer, James Kirkpatrick, Koray Kavukcuoglu, Razvan Pascanu, and Raia Hadsell. Progressive neural networks. *CoRR*, abs/1606.04671, 2016.

[16] Liyuan Wang, Xingxing Zhang, Hang Su, and Jun Zhu. A comprehensive survey of continual learning: Theory, method and application, 2024.

[17] Yeming Wen, Dustin Tran, and Jimmy Ba. Batchensemble: An alternative approach to efficient ensemble and lifelong learning, 2020.

[18] Mitchell Wortsman, Vivek Ramanujan, Rosanne Liu, Aniruddha Kembhavi, Mohammad Rastegari, Jason Yosinski, and Ali Farhadi. Supermasks in superposition. *CoRR*, abs/2006.14769, 2020.

[19] Friedemann Zenke, Ben Poole, and Surya Ganguli. Continual learning through synaptic intelligence. In Doina Precup and Yee Whye Teh, editors, *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *Proceedings of Machine Learning Research*, pages 3987–3995. PMLR, 06–11 Aug 2017.

[20] Chen Zeno, Itay Golan, Elad Hoffer, and Daniel Soudry. Task agnostic continual learning using online variational bayes, 2018.